

基于 ANN 的成人收入二分类模型设计

韦嘉豪

计算机科学与工程系

南方科技大学

12313319@mail.sustech.edu.cn

摘要—本报告提出了一种基于简化神经网络的方法，用于预测个人年收入是否超过 50,000 美元，数据来源于 1994 年美国人口普查局数据库。我们通过多层感知机 (MLP) 实现了一个 ANN 模型，使用 ReLU 激活函数和 softmax 输出层。此模型在验证集上有着良好的表现。实验结果证明了 ANN 的深度学习架构在这个二分类任务上的有效性。

I. 引言

收入预测是社会经济分析和政策制定中的一个基本问题。基于人口统计和就业特征准确预测收入水平的能力在税收政策、社会福利项目和经济研究中具有重要应用价值。

A. 问题背景

成人普查收入数据集由 Kohavi 和 Becker 从 1994 年美国人口普查局数据库中提取，包含个人的人口统计信息，包括年龄、教育程度、职业和其他普查属性。预测任务是确定一个人的年收入是否超过 50,000 美元，这是一个有监督的二分类问题。

B. 研究动机

理解影响收入水平的因素有助于识别经济不平等现象并为政策决策提供信息。机器学习模型可以揭示人口统计特征之间的复杂模式和相互作用，这些模式和相互作用可能无法通过传统统计分析立即显现。

C. 报告组织

本报告组织如下：第二节正式定义问题和符号；第三节描述我们的方法，包括数据预处理和神经网络架构；第四节介绍实验设置和结果；第五节总结讨论和未来工作。

II. 预备知识

A. 问题形式化

我们将收入预测问题形式化为一个有监督的二分类任务。给定数据集 $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$ ，其中：

- $\mathbf{x}_i \in \mathbb{R}^d$ 是一个 d 维特征向量，表示个体 i 的人口统计和普查属性
- $y_i \in \{0, 1\}$ 是二元标签，其中 $y_i = 0$ 表示收入 $\leq \$50K$ ， $y_i = 1$ 表示收入 $> \$50K$
- N 是训练样本总数

目标是学习一个由参数 θ 参数化的分类器 $f_\theta : \mathbb{R}^d \rightarrow \{0, 1\}$ ，使经验风险最小化：

$$\theta^* = \arg \min_{\theta} \frac{1}{N} \sum_{i=1}^N \mathcal{L}(f_\theta(\mathbf{x}_i), y_i) \quad (1)$$

其中 $\mathcal{L}$ 是交叉熵损失函数。

B. 数据集描述

数据集包含 14 个特征，分为两类：

数值特征：

- age: 个体年龄
- fnlwgt: 最终权重（普查抽样权重）
- education_num: 受教育年限
- capital_gain: 资本收益
- capital_loss: 资本损失
- hours_per_week: 每周工作小时数

类别特征：

- workclass: 就业类型（如私营、政府）
- education: 教育水平
- marital_status: 婚姻状况
- occupation: 职业类型
- relationship: 家庭关系

- **race**: 种族
- **sex**: 性别
- **native_country**: 原籍国

C. 符号说明

在本报告中, 我们使用以下符号:

- 粗体小写字母 ($\mathbf{x}$) 表示向量
- 粗体大写字母 ($\mathbf{W}$) 表示矩阵
- $\text{softmax}(\cdot)$ 表示 softmax 激活函数
- $\text{ReLU}(\cdot)$ 表示修正线性单元激活函数
- $h^{(l)}$ 表示第 l 层的隐藏层激活值

III. 方法论

A. 总体工作流程

我们的方法包含三个主要阶段:

- 1) **数据预处理**: 处理缺失值、编码类别特征并归一化数值特征
- 2) **模型训练**: 使用 Adam 优化器和反向传播训练多层感知机
- 3) **评估**: 使用多个指标评估模型性能并生成预测

B. 数据预处理流程

1) **缺失值处理**: 数据集包含用 “?” 表示的缺失值。

我们采用以下策略:

- 对于类别特征: 用众数 (最频繁的值) 替换缺失值
- 对于数值特征: 用中位数替换缺失值

2) **特征编码**: 类别特征使用标签编码, 将每个类别映射为整数值。这种转换是必要的, 因为神经网络需要数值输入。

3) **特征缩放**: 数值特征使用 z-score 标准化:

$$\mathbf{x}_{\text{scaled}} = \frac{\mathbf{x} - \mu}{\sigma} \quad (2)$$

其中 μ 是均值, σ 是在训练集上计算的标准差。

C. 神经网络架构

我们采用多层感知机 (MLP), 架构如下:
网络组成:

- **输入层**: d 个神经元 (预处理后的特征数量)
- **隐藏层**: 三个隐藏层, 分别包含 128、64 和 32 个神经元
- **激活函数**: 每个隐藏层后使用 ReLU 激活函数
- **输出层**: 两个神经元, 使用 softmax 激活函数进行二分类

Algorithm 1 神经网络前向传播

输入: 特征向量 $\mathbf{x} \in \mathbb{R}^d$
输出: 概率向量 $\mathbf{p} \in [0, 1]^2$

$\mathbf{h}^{(0)} \leftarrow \mathbf{x}$
for $l = 1$ **to** L **do**
 $\mathbf{z}^{(l)} \leftarrow \mathbf{W}^{(l)}\mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}$
 $\mathbf{h}^{(l)} \leftarrow \text{ReLU}(\mathbf{z}^{(l)})$
end for
 $\mathbf{z}^{\text{out}} \leftarrow \mathbf{W}^{\text{out}}\mathbf{h}^{(L)} + \mathbf{b}^{\text{out}}$
 $\mathbf{p} \leftarrow \text{softmax}(\mathbf{z}^{\text{out}})$
返回 $\mathbf{p}$

D. 训练过程

1) **损失函数**: 我们使用交叉熵损失函数进行多分类:

$$\mathcal{L}(\theta) = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \log(\hat{y}_{i,c}) \quad (3)$$

其中 $C = 2$ 是类别数量, $y_{i,c}$ 是真实标签 (one-hot 编码), $\hat{y}_{i,c}$ 是类别 c 的预测概率。

2) **优化**: 使用 Adam 优化器训练模型, 学习率 $\alpha = 0.00001$ 。训练过程:

- 批次大小: 128
- 训练轮数: 500
- 训练-验证集划分: 80-20
- 随机种子: 1

E. 复杂度分析

1) **时间复杂度**: 对于具有 L 层和最大宽度 W 的神经网络:

- 前向传播: 每个样本 $O(L \cdot W^2)$
- 反向传播: 每个样本 $O(L \cdot W^2)$
- 训练复杂度: $O(E \cdot N \cdot L \cdot W^2)$, 其中 E 是训练轮数, N 是训练集大小

2) **空间复杂度**: 存储参数的空间复杂度为 $O(d \cdot W + W^2 \cdot L)$, 其中 d 是输入维度。

IV. 实验

A. 实验设置

1) **数据集统计**:

- 训练样本: 22,792 个 (18,233 训练 + 4,559 验证)
- 测试样本: 9,769 个

- 特征数量: 14 个 (预处理前)
- 类别分布: 不平衡, 约 76% 样本属于类别 0 ($\leq 50K$), 24% 样本属于类别 1 ($> 50K$)

2) 实现细节:

- 框架: PyTorch 2.9.1
- 硬件: CPU
- Python 版本: 3.12
- 其他库: NumPy 2.3.5、Pandas 2.3.3、Scikit-learn 1.7.2、Matplotlib 3.10.7

3) 评估指标: 我们使用多个指标评估模型性能:

- 准确率: 预测的总体正确性;
 - 精确率: 预测为正例中真正例的比例;
 - 召回率: 实际正例中被正确预测的比例;
 - F1 分数: 精确率和召回率的调和平均值;
 - ROC-AUC: 受试者工作特征曲线下面积。
- 其中, 我们以提高准确率为训练该模型的主要目的。

B. 结果

1) 训练进程: 图 1展示了 50 个训练轮次中训练和验证的损失/准确率曲线。模型平稳收敛, 没有明显过拟合, 验证指标与训练指标紧密跟踪。




图 1. 训练和验证损失/准确率随训练轮次的变化

2) 性能指标: 表 I展示了验证集上的最终性能指标。

表 I
模型在验证集上的性能

指标	数值
准确率	0.8462
精确率	0.7311
召回率	0.5719
F1 分数	0.6418
ROC-AUC	0.9035

3) 混淆矩阵分析: 图 2展示了验证集上的混淆矩阵。模型在两个类别上都表现良好, 但由于类别不平衡, 对多数类有一定偏向。




图 2. 验证集上的混淆矩阵

4) ROC 曲线: 图 3展示了 ROC 曲线, 证明了模型在各种阈值下区分类别的能力。




图 3. ROC 曲线和 AUC 分数

C. 超参数分析

我们实验了不同的配置:

- 网络深度: 测试了具有 2-4 个隐藏层的架构。三层在容量和简洁性之间提供了最佳平衡。
- 层宽度: 递减宽度 (128→64→32) 优于均匀宽度, 允许逐步特征抽象。
- 学习率: 测试了 {0.00001, 0.0001, 0.001, 0.01}; 0.00001 在不出现不稳定的情况下实现较快收敛, (其余情况在收敛时测试集准确率总会以一定

幅度上下波动，目前看来震荡较小的只有 0.00001，大概在 345 次左右开始收敛)。

- **架构简洁性:** 仅使用 ReLU 激活的简洁架构证明是有效的，无需批归一化或 dropout。

D. 分析与讨论

1) 模型性能: 简化的神经网络在该数据集上取得了具有竞争力的性能。高 ROC-AUC 分数表明在收入类别之间具有强大的判别能力。模型受益于:

- 采用 ReLU 激活
- Softmax 输出提供良好校准的概率估计
- 适当的特征缩放实现高效学习

2) 类别不平衡的影响: 数据集存在类别不平衡 (76% vs 24%)，这影响了模型预测，在之前尝试过的 MLP 训练中，对于 1:1 的数据二分类中直接使用该模型过拟合情况没有本次项目中严重，本次项目过拟合情况具体表现在随着训练的进行测试集准确率有微小下降的趋势。模型在多数类 ($\leq \$50K$) 上显示出更高的准确率，如混淆矩阵所示。未来工作可以通过以下方式解决这个问题:

- 类别加权损失函数
- 对少数类进行过采样 (SMOTE)
- 调整预测阈值
- 采用 Dropout、BatchNorm 等正则化技术来防止过拟合现象的出现

3) 特征重要性: 虽然神经网络通常被认为是”黑盒”，但部分特征可能对预测贡献更大:

- 教育水平和受教育年限
- 职业和每周工作小时数
- 资本收益/损失
- 年龄和婚姻状况

V. 结论

A. 总结

本项目成功将神经网络应用于成人普查收入预测问题。此次的 MLP 在验证集上取得了可观的性能。该方法论证了简洁、直接的 ANN 深度学习架构在表格数据分类任务上的有效性。

B. 关键发现

- 适当的数据预处理对神经网络性能至关重要
- 仅使用 ReLU 激活的简化架构是有效的
- Softmax 激活提供良好校准的概率输出
- 三层架构为此问题提供了足够的容量
- 模型有效处理类别和数值特征

C. 局限性

应该注意以下几个局限性:

- 类别不平衡影响预测偏差
- 标签编码可能无法捕获某些类别特征中的序数关系
- 与决策树相比，模型缺乏可解释性

D. 未来工作

潜在的改进包括:

- 实现类别平衡技术 (SMOTE、类别权重)
- 探索类别特征的 one-hot 编码
- 测试正则化技术 (批归一化、dropout、L2 正则化)
- 特征工程以创建交互项
- 使用网格搜索或贝叶斯优化进行超参数优化
- 使用 SHAP 或 LIME 等技术进行模型解释
- 与其他算法 (随机森林、SVM) 进行比较

E. 经验教训

本项目提供了以下宝贵见解:

- 系统化数据预处理的重要性
- 平衡模型复杂度和泛化能力
- 有效使用 PyTorch 进行分类任务
- 使用多个互补指标进行评估
- 准确率和可解释性之间的权衡